

BÁO CÁO CHUYÊN ĐỀ

Ứng dụng Deep Learning cho ánh xạ điều chế trong hệ thống BIBCM-ID

Trọng tâm: AutoEncoder-based modulation trên kênh vô tuyến không lý tưởng


Học viên: Lại Tiến Đạt

Giáo viên hướng dẫn: TS. Phạm Xuân Nghĩa

Nội Dung Trình Bày

- 1 Tổng quan hệ thống BIBCM-ID và vai trò của thông tin mềm.
- 2 Điều chế số, ánh xạ chòm sao và cơ sở sử dụng ANN/AutoEncoder.
- 3 Mô hình kênh không lý tưởng: PA phi tuyến, CFO và fading Rayleigh.
- 4 Các kiến trúc AutoEncoder cho ánh xạ điều chế và giải điều chế.
- 5 Kết quả mô phỏng, khả năng tích hợp LLR và kết luận.

BIBCM-ID: Bối Cảnh Hệ Thống



Ba thành phần cốt lõi

- **Modulation/Demodulation:** ánh xạ bit sang chòm sao và trích thông tin mềm.
- **Channel coding:** tạo dư thừa sửa lỗi, thường dùng LDPC/Turbo/Polar.
- **Interleaver:** phá tương quan lỗi và hỗ trợ giải mã lặp.

Trong BIBCM-ID, chất lượng LLR từ Demodulation ảnh hưởng trực tiếp đến hội tụ giải mã kênh.

Điều Chế Số Và Khả Năng Thay Thế Bằng ANN

Điều chế là một ánh xạ phi tuyến

Với $M = 2^k$, bộ điều chế thực hiện

$$f_{\text{mod}} : \{0, 1\}^k \rightarrow \mathbb{R}^2, \quad \mathbf{b} \mapsto x_I + jx_Q.$$

- ▶ 16-QAM dùng bảng ánh xạ cố định.
- ▶ Khi PA/CFO/fading xuất hiện, hình học tối ưu không nhất thiết còn là lưới vuông.

Vì sao ANN phù hợp?

- ▶ MLP xấp xỉ tốt các ánh xạ phi tuyến liên tục.
- ▶ Encoder học vị trí điểm IQ; Decoder học biên quyết định và xác suất hậu nghiệm.
- ▶ Huấn luyện end-to-end tối ưu theo kênh thực tế thay vì theo giả thiết AWGN lý tưởng.


$$\theta^* = \arg \min_{\theta} \mathbb{E}\{\mathcal{L}(\mathbf{b}, \hat{\mathbf{b}}_{\theta})\}.$$

Intelligent AutoEncoder-Based Modulation

Tối ưu hiệu năng truyền dẫn trên kênh vô tuyến không lý tưởng

Mục tiêu báo cáo

Trình bày cơ sở khoa học, mô hình triển khai và kết quả mô phỏng của bộ thu phát học sâu dạng AutoEncoder, tập trung vào PA phi tuyến, CFO, fading Rayleigh và khả năng liên kết với giải điều chế mềm.




Đặt Vấn Đề: Vì Sao Cần Học Điều Chế?

Giả thiết thiết kế cổ điển

16-QAM, PSK/QAM bậc cao và bộ giải điều chế thường được tối ưu trong mô hình AWGN hoặc các khối suy hao được bù riêng rẽ.

- ▶ PA làm nén biên độ và méo hình học chòm sao.
- ▶ CFO gây quay pha tích lũy theo thời gian.
- ▶ Fading Rayleigh làm biến thiên kênh và giảm khoảng cách hiệu dụng.



Vấn đề cốt lõi

Tối ưu cục bộ không bảo đảm tối ưu toàn tuyến.

Khoảng Trống Nghiên Cứu Và Đóng Góp

Khoảng trống

Nhiều nghiên cứu AE xét AWGN hoặc một suy hao riêng lẻ. Hướng nghiên cứu này khảo sát kênh tổng hợp gồm PA, CFO và fading trong một mô hình khả vi.

- ▶ Không chỉ học chòm sao trong kênh lý tưởng.
- ▶ Không giả thiết luôn có PLL hoặc pilot để bù CFO.
- ▶ Không tách cứng điều chế và mã hóa kênh.

Ba đóng góp chính

- 1 AE đơn ký hiệu học chòm sao kháng PA.
- 2 AE nhiều ký hiệu bù CFO mù bằng học chuỗi.
- 3 Neural FEC tích hợp điều chế và dư thừa sửa lỗi.


Cơ sở: O'Shea & Hoydis 2017; Cammerer et al. 2020; Aoudia & Hoydis 2022.

Mô Hình Kênh Không Lý Tưởng

$$x[n] = a_I[n] + ja_Q[n],$$


$$y[n] = \sum_{\ell=0}^{L_h-1} h[\ell] \phi(x[n-\ell]) e^{j2\pi\Delta f T_s n} + w[n].$$

- ▶ $\phi(\cdot)$: biến đổi PA theo mô hình Rapp.
- ▶ $e^{j2\pi\Delta f T_s n}$: quay pha do CFO.
- ▶ $h[\ell] \sim \mathcal{CN}(0, \sigma_\ell^2)$: fading Rayleigh.



Chuỗi suy hao được đưa vào lớp kênh khả vi để huấn luyện end-to-end.

Cơ Sở AutoEncoder Cho Lớp Vật Lý



Diễn giải truyền thông

- ▶ Encoder: ánh xạ bit/ký hiệu sang điểm IQ.
- ▶ Channel layer: mô phỏng suy hao vật lý.
- ▶ Decoder: ước lượng hậu nghiệm ký hiệu hoặc bit.

$$\theta^* = \arg \min_{\theta} \mathbb{E}[\mathcal{L}(s, \hat{s}_{\theta}(y))].$$

Ý nghĩa. Điều chế và giải điều chế được tối ưu đồng thời theo tiêu chuẩn lỗi trên chính phân bố suy hao của kênh.


Kiến Trúc 1: AE Đơn Ký Hiệu Kháng PA

Luồng xử lý

One-hot $s \in \{0, 1\}^{16} \rightarrow \text{MLP Encoder} \rightarrow \text{IQ} \rightarrow \text{PA}$
+ Rayleigh + AWGN $\rightarrow \text{MLP Decoder} + \text{Softmax}.$


$$x_{\text{norm}} = \frac{x_{\text{raw}}}{\sqrt{\mathbb{E}\|x_{\text{raw}}\|^2 + \epsilon}}.$$

$$\mathcal{L} = \mathcal{L}_{CE} + \lambda_P \mathbb{E} \left[\max(\|x\| - \gamma A_{\text{sat}}, 0)^2 \right].$$




Hàm phạt công suất ép chòm sao tránh vùng bão hòa PA.


Học Hình Học Chòm Sao Dưới Méo PA



16-QAM trước PA



16-QAM sau PA




Chòm sao AE học được

Nhận xét kỹ thuật

AE không giữ lưới chữ nhật đều như 16-QAM; các điểm được phân bố lại để tránh vùng nén biên độ và tăng khoảng cách hiệu dụng sau PA.

Kết Quả 1: Rayleigh + PA + AWGN




Kết quả chính

- ▶ Từ khoảng $\text{SNR} \geq 14$ dB, AE tách khỏi 16-QAM + ZF.
- ▶ Tại $\text{BER } 10^{-2}$: lợi SNR khoảng **3–4 dB**.
- ▶ Tại 34 dB: $\text{BER AE} \approx 6 \times 10^{-4}$, thấp hơn khoảng **4 lần**.

Điểm mạnh xuất hiện rõ khi nhiễu cộng không còn là suy hao chi phối.

Kiến Trúc 2: AE Nhiều Ký Hiệu Cho Bù CFO Mù




Ý tưởng

Encoder dùng Time-Distributed MLP để tạo chuỗi L ký hiệu; Decoder quan sát cả block nhận được để suy ra xu thế quay pha.

$$y_{\text{cfo}}[n] = x_{\text{pa}}[n]e^{j2\pi\Delta f T_s n} + w[n].$$

- ▶ $\Delta f T_s$ thay đổi trong huấn luyện nhưng không cấp trực tiếp cho Decoder.
- ▶ Decoder học bù CFO mù, không dùng PLL/pilot.

CFO: Từ Méo Quỹ Đạo Đến Lợi Ích Học Chuỗi



CFO tạo quỹ đạo quay pha tích lũy theo chỉ số ký hiệu.


Cơ chế học

AE không ước lượng CFO bằng công thức tường minh; mạng học ánh xạ phi tuyến từ hình dạng quỹ đạo nhận được về chuỗi ký hiệu ban đầu.


- ▶ Quyết định theo block làm giảm nhạy với nhiễu tức thời.
- ▶ Tín hiệu tương quan theo thời gian trở thành nguồn thông tin để bù pha.

$$\hat{\mathbf{s}} = \arg \max_{\mathbf{s}} p_{\theta}(\mathbf{s} \mid \mathbf{y}_{1:L}, \text{SNR}).$$

Kết Quả 2: Bù CFO Mù Trên Kênh Tổng Hợp



$$\Delta f T_s = 0.005$$



$$\Delta f T_s = 0.01$$

Kết luận từ mô phỏng

Khi CFO tăng, 16-QAM + ZF xuất hiện error floor; AE vẫn giảm BER theo SNR và đạt lợi khoảng **5–8 dB** tại BER 10^{-2} .


Kiến Trúc 3: Neural FEC Kết Hợp Điều Chế Và Sửa Lỗi

Khác biệt so với điều chế cổ điển

Thay vì ánh xạ k bit vào một ký hiệu duy nhất, Encoder ánh xạ k bit vào N điểm IQ, tạo dư thừa trong miền Euclid.

$$R = \frac{k}{2N}, \quad \hat{b}_i = \sigma(f_{\theta,i}(\mathbf{y}_{1:N})).$$

- ▶ Đầu vào: vector bit thô, không cần one-hot.
- ▶ Đầu ra: xác suất từng bit bằng Sigmoid.



AE 4 → 6 đạt BER < 10⁻⁴ ở khoảng 8 dB trong kịch bản đánh giá.

Huấn Luyện: Curriculum Learning Và Hàm Mất Mát Có Ràng Buộc

Curriculum learning

Huấn luyện đi từ kênh dễ đến kênh khó: SNR cao $\rightarrow$ dải SNR rộng; CFO nhỏ $\rightarrow$ CFO lớn; sau cùng tinh chỉnh với learning rate thấp.

Tham số	Sc.1	Sc.2	Sc.3
Số pha	3	4	3
Batch	4096	4096	4096
Max CFO	0	0.03	0.03
$A_{sat,p}$	1,2,3	1,2,3	1,2,3
Optimizer	Adam	Adam	Adam

$$\mathcal{L}_2 = \mathcal{L}_{CE} + \lambda_P P_{\text{sat}} + \lambda_D \max(d_{\text{target}}^2 - d_{\text{min}}^2, 0).$$


- ▶ Gradient clipping $\|\nabla\| \leq 1$.
- ▶ BatchNorm, dropout nhẹ, early stopping.

Khả Năng Tích Hợp: Soft LLR Và BIBCM-ID/LDPC

$$L(b_i) = \ln \frac{\sum_{m:b_i(m)=1} P(s_m | \mathbf{y})}{\sum_{m:b_i(m)=0} P(s_m | \mathbf{y})}.$$

Điểm quan trọng

Softmax của Decoder không chỉ cho hard decision, mà còn cung cấp xác suất hậu nghiệm để trích LLR mềm cho bộ giải mã Turbo/LDPC.



- ▶ Phù hợp với tư duy BIBCM-ID: trao đổi thông tin mềm giữa Demodulation và giải mã kênh.
- ▶ AE có thể được xem như bộ Demodulation thông minh trong chuỗi thu hiện hữu.

Kết Luận Và Hướng Phát Triển

Kết luận chính

- ▶ AE học chòm sao kháng PA, đạt lợi SNR **3–4 dB**.
- ▶ AE nhiều ký hiệu bù CFO mù, đạt lợi **5–8 dB** so với 16-QAM + ZF trong kịch bản CFO.
- ▶ Neural FEC cho thấy khả năng hợp nhất điều chế và sửa lỗi trong một ánh xạ học được.

Giới hạn và hướng tiếp theo

- ▶ Cần kiểm chứng trên OFDM và kênh chọn lọc tần số.
- ▶ Cần đánh giá độ phức tạp, lượng tử hóa và SDR.
- ▶ Cần mở rộng giao diện LLR để tích hợp chặt với LDPC/BIBCM-ID.

Tài liệu nền: Proakis & Salehi 2008; O'Shea & Hoydis 2017; Cammerer et al. 2020; Aoudia & Hoydis 2022.